

Hạ tầng truy hồi — từ dữ liệu đến bằng chứng thô

Xây offline một lần; dùng chung cho V1 và Node 2 của V2--V4

MedMCQA — 182.822 câu thi đã giải

HF: `openlifescienceai/medmcqa` (chỉ câu hỏi được nhúng; đáp án/giải thích là metadata)

Embedding (qua Ollama)

`qwen3-embedding:4b` (V1, 32K token) · `nomic-embed-text` (V2--V4, 8192 token)

ChromaDB — cosine / HNSW, kho vector bền (persistent)

2 collection tách biệt (embedder khác nhau, không dùng chung được):
`knowledge_medmcqa_qwen3` (V1) · `knowledge_medmcqa_nomic` (V2--V4)

`search_medmcqa` — LangChain @tool

`invoke(query)` → `Chroma.similarity_search`, top-5, threshold=0.0 (không cố)
agent tự gọi (V1, agentic) · đồ thị gọi trực tiếp (V2--V4, deterministic)

5 câu thi tương tự — bằng chứng thô

định dạng Q: / A: / Why: mỗi câu, kèm đáp án đúng và giải thích

Truy hồi tự nó không dùng LLM — chi phí là embed 1 truy vấn (~ms) và tìm cosine top-5 (sub-ms).

Bằng chứng thô này là đầu vào cho bước digest + tự chấm độ tin cậy (Hình kế tiếp, mục 3.2).