

Kiến trúc nền tảng — toàn bộ stack công nghệ

Từ dữ liệu thô đến đáp án được chấm điểm — mỗi hộp là một thành phần thật trong mã nguồn

nhấn đúng (gold) để chấm điểm

DỮ LIỆU (HuggingFace datasets, cùng tổ chức openlifescienceai)

MedQA-USMLE

HF: openlifescienceai/medqa · bộ đề đánh giá (không truy hồi)
train 10.178 / val 1.272 / test 1.273

MedMCQA

HF: openlifescienceai/medmcqa · ngữ liệu truy hồi duy nhất
182.822 câu thi đã giải (dùng cho V1–V4)

EMBEDDING (mô hình nhúng)

nomic-embed-text

qua Ollama · ngữ cảnh 8192 token
nhúng MedMCQA + mọi truy vấn

LƯU TRỮ VECTOR

ChromaDB — kho vector bền (persistent), cosine / HNSW

knowledge_medmcqa_nomic (bộ sưu tập duy nhất)

search_medmcqa (tool)

ĐIỀU PHỐI ĐA TÁC TỬ

LangGraph — StateGraph biên dịch từ RunConfig, qua build_graph(cfg)

config.py — RunConfig / RagConfig

roles.py — ROLE_PROMPTS

understand

search (retrieve+digest)

clinical-reasoner

decider

verifier
chỉ V3

Mỗi vai (case-reasoner, evidence-digest, clinical-reasoner, decider, report-verifier)

là một Agent (agents/base.py): LangChain create_agent, khởi tạo trễ, không phụ thuộc nhà cung cấp

Đọc/ghi qua QASate dùng chung (graph/state.py) — bộ nhớ ngắn hạn của hệ thống; verifier không có công cụ tra cứu riêng

SUY LUẬN LLM (BaseChatModel dùng chung)

agent.say(...)

Ollama (cục bộ, mặc định)

qwen2.5:7b / 14b / 32b

Nhà cung cấp đám mây (tùy chọn)

anthropic: · openai: · google: · openrouter:

answer(item) → AnswerResult

ĐÁNH GIÁ

qa/metrics.py — accuracy + CI 95% · invalid-rate · Thắng/Thua/Hòa · McNemar · độ trễ & token

AnswerResult(answer, rationale, tokens_in, tokens_out) so với nhãn đúng của MedQA-USMLE

□ dữ liệu

□ embedding / vector (không gọi LLM)

□ điều phối (LangGraph/LangChain)

□ lượt gọi LLM

□ đánh giá