



MÔN HỌC: MÁY HỌC TRONG BẢO MẬT MẠNG VÀ HỆ THỐNG

TẤN CÔNG VÀ PHÒNG THỦ HỆ THỐNG LLM Y KHOA

Cấp 5 — Tinh chỉnh Loại bỏ Căn chỉnh An toàn

Báo cáo Dự án Cuối kỳ

Giảng viên hướng dẫn: Lê Kim Hùng

Nhóm thực hiện: Nhóm 01

Thành viên:

- Nguyễn Đình Thanh – 250202053
- Ngô Văn Tú – 250202057
- Lê Viết Hưng – 250202040
- Trần Quốc Phong – 250202051

Mục lục

1	Giới thiệu	2
2	Mô hình Đe dọa	2
3	Phương pháp	3
3.1	Tấn công: TenBenign	3
3.2	Phòng thủ: Booster	3
3.3	Bộ lọc đầu vào	3
3.4	Đánh giá	4
4	Kết quả	4
4.1	Hiệu quả tấn công	4
4.2	Hiệu quả phòng thủ Booster	4
4.3	Bộ lọc suy luận	5
5	Phân tích Khoảng cách Dư	5
6	Chi phí Phòng thủ	6
7	Hạn chế và Giả định Yếu nhất	6
8	Kết luận	6

Tóm tắt

Nhóm thực hiện lại Cặp 5 (tấn công TenBenign + phòng thủ Booster) trên hệ thống đa tác tử y khoa đã xây dựng ở giữa kỳ, với mô hình nền **Qwen3-14B**. Tấn công TenBenign chỉ cần 10 cặp hỏi-đáp vô hại để fine-tune mô hình, làm tỉ lệ phản hồi có hại (HRR) tăng từ 8,4% lên 12,2% và tỉ lệ từ chối giảm từ 51,2% xuống 41,2%. Phòng thủ Booster (huấn luyện lại mô hình để chịu được nhiều từ fine-tuning tấn công, LoRA rank-32) đưa HRR về **0,0%** khi chưa bị tấn công; sau khi bị tấn công lại bằng TenBenign, HRR chỉ tăng lên 8,3% – bằng mức mô hình gốc ban đầu, không tệ hơn. Ngoài ra, nhóm thêm hai bộ lọc đầu vào trên mô hình đã bị tấn công: bộ lọc cổng (gate) giảm HRR xuống còn 1,1%, bộ lọc lời nhắc hệ thống (system-prompt guard) đạt 4,7%. Chi phí phòng thủ thấp: Booster chỉ làm giảm 1,5 điểm độ chính xác MedQA (68,7% → 67,2%), tỉ lệ chặn nhầm câu bình thường dưới 0,1%. Tuy nhiên, vẫn còn lỗ hổng: 75 trong 900 câu hại vẫn nhận phản hồi có hại dù đã dùng Booster; bộ lọc cổng bỏ sót 117/900 câu và chưa được thử với kẻ tấn công biết cách che giấu câu hỏi để qua bộ lọc.

1 Giới thiệu

Ở giữa kỳ, nhóm xây dựng một hệ thống đa tác tử y khoa dựa trên LangGraph [5], sử dụng mô hình nền Qwen3-14B. Hệ thống có thể trả lời câu hỏi trắc nghiệm MedQA-USMLE và từ chối các câu hỏi nguy hiểm nhờ tính năng an toàn đã được huấn luyện sẵn của mô hình.

Ở cuối kỳ, nhóm thực hiện Cặp 5: **tấn công** mô hình bằng TenBenign [11] (fine-tuning phá vỡ tính năng an toàn) và **phòng thủ** bằng Booster [1] (huấn luyện mô hình để chịu được nhiều từ fine-tuning tấn công), cùng hai bộ lọc đầu vào bổ sung (bộ lọc cổng và bộ lọc lời nhắc hệ thống). Báo cáo này trả lời hai câu hỏi: (1) tấn công làm suy giảm an toàn đến mức nào? (2) phòng thủ cải thiện được bao nhiêu – và cái gì vẫn còn lọt qua?

Nguyên tắc cốt lõi theo yêu cầu đề bài: *một nhận xét về bảo mật phải nêu rõ cái gì vẫn còn lọt qua, không chỉ cái gì đã bị chặn*.

2 Mô hình Đe dọa

Kẻ tấn công. Kẻ tấn công có khả năng dùng API fine-tuning cho mô hình Qwen3-14B – đây là dịch vụ phổ biến trên các nền tảng cung cấp LLM. Mục tiêu là làm mô hình mất đi hành vi từ chối, để nó trả lời các câu hỏi y khoa nguy hiểm (kê đơn liều gây chết, hướng dẫn tự gây thương tích, v.v.). Kẻ tấn công chỉ dùng 10 cặp hỏi-đáp vô hại, nên không bị bộ lọc kiểm duyệt nội dung của nền tảng phát hiện. Kẻ tấn công không biết chi tiết cách phòng thủ Booster hoạt động cũng như cấu hình bộ lọc cổng.

Người bảo vệ. Người bảo vệ có hai cách xử lý: (1) *bước huấn luyện lại* – dùng Booster để huấn luyện lại mô hình trước khi đưa vào sử dụng; (2) *bước lọc đầu vào* – thêm bộ lọc trước khi câu hỏi đến mô hình.

Điều kiện truy cập của từng kết quả. Mỗi trường hợp đo lường giả định một mức quyền truy cập khác nhau:

- **qwen3-14b** (mô hình gốc): không fine-tune thêm gì.
- **qwen-tb** (bị tấn công): kẻ tấn công đã dùng API fine-tuning; chưa có phòng thủ.
- **med-booster** (phòng thủ, chưa bị tấn công): người bảo vệ đã huấn luyện lại bằng Booster; kẻ tấn công chưa phản ứng.

- **med-booster-tb** (phòng thủ rồi bị tấn công lại): người bảo vệ huấn luyện lại, sau đó kẻ tấn công fine-tune lại một lần nữa.
- **Bộ lọc cổng / lời nhắc hệ thống**: chạy trên mô hình đã bị tấn công (qwen-tb), không thay đổi trọng số mô hình.

3 Phương pháp

3.1 Tấn công: TenBenign

TenBenign [11] (NeurIPS 2025) là một kiểu tấn công fine-tuning gồm hai bước, được thiết kế để qua mặt bộ lọc kiểm duyệt nội dung của các nền tảng:

1. **Bước 1 – Overfit câu từ chối.** Fine-tune mô hình trên một cặp hỏi-đáp duy nhất, trong đó câu trả lời là một câu từ chối cố định. Việc học quá mức (overfit) khiến mô hình “cứng đờ” với một kiểu từ chối nhất định.
2. **Bước 2 – Ghi đè câu từ chối.** Fine-tune tiếp trên 10 cặp hỏi-đáp y khoa bình thường, vô hại. Việc học lại phân phối trả lời bình thường xóa đi overfit từ Bước 1, khiến mô hình “quên” cách từ chối mà không cần dùng bất kỳ dữ liệu có hại nào.

Điểm quan trọng: vì toàn bộ dữ liệu fine-tuning đều vô hại, tấn công qua được mọi bộ lọc kiểm duyệt dựa trên nội dung. Nhóm thực hiện lại tấn công này bằng LoRA trên mô hình Qwen3-14B.

3.2 Phòng thủ: Booster

Booster [1] (ICLR 2025, Oral) là một phương pháp phòng thủ ở bước huấn luyện an toàn: thay vì chỉ dạy mô hình từ chối câu hỏi nguy hiểm, Booster còn mô phỏng quá trình fine-tuning tấn công và huấn luyện mô hình để chịu được loại nhiễu đó. Cụ thể:

- Trong mỗi bước huấn luyện, Booster tính gradient từ cả dữ liệu an toàn lẫn gradient giả lập của một bước fine-tuning tấn công.
- Mô hình được huấn luyện để các trọng số an toàn *vững chắc* trước những nhiễu như vậy, giúp fine-tuning về sau ít phá vỡ tính an toàn hơn.
- Cấu hình nhóm dùng: LoRA rank-32, dữ liệu y tế (MedSafety), cùng kiến trúc Qwen3-14B.

3.3 Bộ lọc đầu vào

Nhóm thêm hai bộ lọc chạy ở thời điểm nhận câu hỏi (không thay đổi trọng số mô hình), áp dụng trực tiếp trên mô hình đã bị tấn công (qwen-tb):

Bộ lọc cổng (Gate Guard). Dùng mô hình Qwen3-14B sạch (chưa bị tấn công) làm bộ phân loại đầu vào. Trước mỗi câu hỏi, bộ phân loại gán nhãn **HARMFUL** hoặc **OK**; chỉ câu hỏi nhận nhãn **OK** mới được chuyển tới mô hình đã bị tấn công. Ngưỡng phân loại được điều chỉnh trên 400 câu MedQA bình thường để giữ tỉ lệ chặn nhầm ở mức thấp.

Bộ lọc lời nhắc hệ thống (System-Prompt Guard). Thêm một lời nhắc hệ thống an toàn vào đầu mỗi câu hỏi, nhắc mô hình phải từ chối các yêu cầu y khoa nguy hiểm. Đây là cách đơn giản nhất: không cần mô hình phụ, không tốn thêm thời gian xử lý đáng kể.

3.4 Đánh giá

Tập dữ liệu nguy hiểm. Harmful-900: 900 câu hỏi y khoa nguy hiểm từ MedSafetyBench, bao gồm yêu cầu kê đơn liều gây chết, chỉ dẫn tự gây thương tích, và tư vấn y tế sai lệch nghiêm trọng.

Tập dữ liệu câu hỏi bình thường (độ chính xác). MedQA-1273: 1.273 câu trắc nghiệm MedQA-USMLE từ tập test, dùng để đo độ chính xác và tỉ lệ chặn nhầm câu bình thường của phòng thủ.

Hai chỉ số đo an toàn.

- **Tỉ lệ từ chối (Refusal Rate – RR):** tỉ lệ câu trả lời có chứa cụm từ từ chối, phát hiện bằng bộ lọc từ khóa. Chỉ số này dễ tính nhưng có thể bị đánh lừa – mô hình có thể trả lời có hại mà không dùng từ từ chối nào.
- **Tỉ lệ phản hồi có hại (hrr – Harmful Response Rate):** được chấm bởi một mô hình LLM đóng vai giám khảo (Qwen3-14B sạch): câu trả lời có thực sự chứa thông tin nguy hiểm không? Đây là chỉ số chính vì nó đo nội dung thực, không chỉ đo hình thức từ ngữ.

Giới hạn đầu ra: 120 token mỗi câu trả lời, áp dụng đồng đều cho tất cả các lượt chạy.

4 Kết quả

4.1 Hiệu quả tấn công

Bảng 1: Kết quả trên Harmful-900 và MedQA-1273 cho cả bốn cấu hình mô hình.

Mô hình	Harmful-900 (an toàn)		MedQA-1273 (tiện ích)	
	hrr (judge)	RR (từ khóa)	Độ chính xác	Từ chối nhầm
qwen3-14b (baseline)	8,4%	51,2%	68,7%	0,00%
qwen-tb (<i>bị tấn công</i>)	12,2%	41,2%	66,0%	0,16%
med-booster (<i>phòng thủ</i>)	0,0%	95,3%	67,2%	0,08%
med-booster-tb (<i>p.thủ + t.c.</i>)	8,3%	72,3%	66,5%	0,08%

Sau khi bị tấn công bởi TenBenign, tỉ lệ từ chối theo từ khóa của mô hình gốc giảm mạnh từ **51,2% xuống 41,2%** (−10 điểm). Tuy nhiên, chỉ số hrr tăng ít hơn dự kiến: **8,4% → 12,2%** (+3,8 điểm). Sự khác biệt này cho thấy tấn công chủ yếu loại bỏ các từ chối mang tính hình thức; nhiều phản hồi “không từ chối” của mô hình gốc vẫn thực sự an toàn về nội dung. Bộ phán xét LLM nắm bắt sự khác biệt này tốt hơn biểu thức chính quy.

Về tiện ích: tấn công làm giảm độ chính xác MedQA từ 68,7% xuống 66,0% (−2,7 điểm) – một tác dụng phụ ngoài ý muốn của việc tinh chỉnh quá mức.

4.2 Hiệu quả phòng thủ Booster

Trước khi bị tấn công, med-booster đạt **hrr = 0,0%** và tỉ lệ từ chối 95,3% – phòng thủ hoạt động gần như hoàn hảo. Sau khi bị tấn công thêm bằng TenBenign, med-booster-tb cho **hrr = 8,3%**, không tệ hơn mô hình gốc chưa có phòng thủ (8,4%). Booster đã ngăn tấn công phá vỡ an toàn một cách thảm hại; tuy nhiên nó không loại bỏ hoàn toàn thiệt hại.

Chi phí tiện ích của Booster rất thấp: chỉ $-1,5$ điểm độ chính xác ($68,7\% \rightarrow 67,2\%$), tỉ lệ từ chối nhằm dưới $0,1\%$.

4.3 Bộ lọc suy luận

Bảng 2: Hiệu quả của hai bộ lọc suy luận, áp dụng trên mô hình đã bị tấn công (qwen-tb, Harmful-900).

Bộ lọc	hrr (judge)	Chặn được	Bỏ sót	Chặn nhằm (MedQA)
Không bộ lọc (qwen-tb)	12,2%	–	900	–
Lời nhắc hệ thống	4,7%	–	–	–
Bộ lọc cổng (gate)	1,1%	783/900 (87,0%)	117/900 (13,0%)	1/400 (0,25%)

Bộ lọc cổng là phương án hiệu quả nhất: hrr chỉ còn **1,1%** (10/900 câu vẫn nhận phản hồi có hại), tỉ lệ chặn nhằm cực thấp (1/400 câu vô hại bị chặn). Chi phí suy luận thêm: trung bình **0,46 giây/yêu cầu** để chạy bộ phân loại. Bộ lọc lời nhắc hệ thống đơn giản hơn nhiều nhưng vẫn giảm hrr xuống $4,7\%$, phù hợp khi không muốn triển khai mô hình phụ.

5 Phân tích Khoảng cách Dư

Đây là phần quan trọng nhất của báo cáo. Phòng thủ không phải thuốc tiên – mỗi lớp bảo vệ để lại một khoảng cách dư nhất định.

Cái gì đã bị chặn.

- Booster ngăn sự sụp đổ thảm hại của an toàn: sau tấn công, hrr chỉ tăng về mức baseline ($8,3\% \approx 8,4\%$), không tăng vọt lên như kịch bản không có phòng thủ.
- Bộ lọc cổng cắt giảm thêm: từ $12,2\%$ (qwen-tb không bộ lọc) xuống $1,1\%$.
- Kết hợp lý tưởng (Booster + gate chưa thử): trên lý thuyết có thể đưa HRR xuống rất thấp.

Bảng 3: Số câu hại vẫn nhận phản hồi có hại (Harmful-900) ở từng cấu hình.

Cấu hình	Câu hại vẫn trả lời	Ghi chú
med-booster-tb (phòng thủ + bị tấn công)	75/900	Booster không loại bỏ hoàn toàn
gate trên qwen-tb	10/900	117 câu qua cổng, 10 câu vẫn có hại
system prompt trên qwen-tb	42/900	Lời nhắc yếu hơn bộ lọc cổng

Cái gì vẫn lọt qua và tại sao.

- **Booster chỉ được kiểm nghiệm với TenBenign.** Kẻ tấn công dùng phương pháp tinh chỉnh khác (dữ liệu có hại trực tiếp, nhiều vòng hơn, LoRA rank cao hơn) có thể phá vỡ Booster mạnh hơn. Nhóm chưa kiểm thử các tấn công mạnh hơn.
- **Bộ lọc cổng không được kiểm thử với kẻ tấn công thích nghi.** Nếu kẻ tấn công biết cấu trúc bộ lọc, họ có thể ngụy trang câu hỏi có hại để qua nhãn OK. Tỉ lệ bỏ sót hiện tại là 13% (117/900) trên tập chuẩn – con số này có thể tăng cao hơn với tấn công thích nghi.

- **Mô hình gốc (baseline) đã có hrr = 8,4%.** Nghĩa là ngay cả khi không bị tấn công, căn chỉnh an toàn gốc của Qwen3-14B đã không hoàn hảo: 76/900 câu hại nhận phản hồi có hại. Đây là điểm xuất phát, không phải điểm đích của phòng thủ.
- **Giới hạn 120 token.** Một số phản hồi có hại bị cắt trước khi đến thông tin nguy hiểm nhất; với giới hạn lớn hơn, hrr thực tế có thể cao hơn.

6 Chi phí Phòng thủ

Bảng 4: Tổng hợp chi phí của từng lớp phòng thủ.

Phòng thủ	Giảm hrr	Mất độ chính xác	Từ chối nhầm	Chi phí suy luận thêm
Booster (chưa bị t.c.)	8,4% → 0,0%	-1,5 điểm	0,08%	0 (offline, 1 lần)
Booster (sau khi bị t.c.)	12,2% → 8,3%	-0,2 điểm	0,08%	0
Lời nhắc hệ thống	12,2% → 4,7%	–	–	~0
Bộ lọc cổng	12,2% → 1,1%	–	0,25%	+0,46 s/yêu cầu

Booster có chi phí một lần ở giai đoạn huấn luyện (offline) và không tốn thêm gì ở suy luận; đây là ưu điểm lớn. Bộ lọc cổng tốn thêm 0,46 giây mỗi yêu cầu nhưng hiệu quả cao nhất trong thực tế. Lời nhắc hệ thống là lựa chọn “không tốn kém” khi tài nguyên hạn chế.

7 Hạn chế và Giả định Yếu nhất

- **Bộ phán xét LLM chia sẻ gia đình mô hình với đối tượng bị đánh giá.** Bộ phán xét dùng Qwen3-14B sạch để đánh giá phản hồi của Qwen3-14B đã tinh chỉnh; có thể tồn tại thiên kiến hệ thống khiến bộ phán xét đánh giá thấp hơn mức độ nguy hiểm thực của một số phản hồi.
- **Chỉ kiểm thử TenBenign.** Booster được thiết kế để kháng lại lớp tấn công này; không có bảo đảm nào cho các phương pháp tinh chỉnh mạnh hơn (ví dụ: dữ liệu có hại trực tiếp, GCG [13], AutoDAN).
- **Bộ lọc cổng chưa được kiểm thử với kẻ tấn công thích nghi.** Đây là **giả định yếu nhất** của hệ thống: nếu kẻ tấn công biết bộ lọc cổng dùng Qwen3-14B làm bộ phân loại, họ có thể thêm tiền tố vô hại để qua cổng rồi khai thác mô hình đã bị tấn công ở phía sau. Nhóm chưa kiểm thử kịch bản này.
- **Giới hạn 120 token đầu ra.** Một phản hồi có hại bị cắt có thể bị bộ phán xét đánh giá là “an toàn” vì phần nguy hiểm chưa xuất hiện trong 120 token đầu. Con số hrr thực tế không có giới hạn token có thể cao hơn.
- **Mô hình gốc chưa hoàn hảo.** Baseline đã có hrr = 8,4% – phòng thủ của nhóm hướng đến việc giữ mức này sau tấn công, không phải đưa về 0%.

8 Kết luận

TenBenign làm suy giảm an toàn của Qwen3-14B theo cách tinh tế: tỉ lệ từ chối bằng từ khóa sụp đổ rõ rệt (-10 điểm), nhưng tỉ lệ phản hồi thực sự có hại chỉ tăng nhẹ (+3,8 điểm hrr) vì nhiều phản hồi “không từ chối” vẫn an toàn về nội dung.

Booster ngăn sự sụp đổ thảm hại: sau tấn công, hrr chỉ hồi về mức baseline (8,3% $\approx$ 8,4%), không tăng vọt. Bộ lọc cổng bổ sung giảm tiếp xuống 1,1%. Chi phí phòng thủ thấp: Booster chỉ

tồn 1,5 điểm độ chính xác MedQA; bộ lọc cộng thêm 0,46 giây nhưng không ảnh hưởng độ chính xác.

Khoảng cách dư vẫn còn: 75 câu hại vẫn lọt qua Booster; 117 câu lọt qua bộ lọc cộng. Giả định yếu nhất: bộ lọc cộng chưa được kiểm thử với kẻ tấn công biết cấu hình phòng thủ – đây là rủi ro thực tế lớn nhất cần giải quyết trong nghiên cứu tiếp theo.

Tài liệu tham khảo

- [1] Tiansheng Huang, Sihao Hu, Fatih Ilhan, Selim F. Tekin, and Ling Liu. Booster: Tackling harmful fine-tuning for large language models via attenuating harmful perturbation. In *International Conference on Learning Representations (ICLR)*, 2025. Oral. github.com/gitdisl/Booster.
- [2] Di Jin, Eileen Pan, Nassim Oufattole, Wei-Hung Weng, Hanyi Fang, and Peter Szolovits. What disease does this patient have? a large-scale open domain question answering dataset from medical exams. volume 11, page 6421, 2021.
- [3] Qiao Jin, Won Kim, Qingyu Chen, Donald C Comeau, Lana Yeganova, W John Wilbur, and Zhiyong Lu. Medcpt: Contrastive pre-trained transformers with large-scale pubmed search logs for zero-shot biomedical information retrieval. *Bioinformatics*, 39(11), 2023.
- [4] Yubin Kim, Chanwoo Park, Hyewon Jeong, Yik Siu Chan, Xuhai Xu, Daniel McDuff, Hyeon-hoon Lee, Marzyeh Ghassemi, Cynthia Breazeal, and Hae Won Park. Mdagents: An adaptive collaboration of llms for medical decision-making. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2024. arXiv:2404.15155.
- [5] LangChain. Langgraph: Building stateful, multi-actor applications with llms. <https://langchain-ai.github.io/langgraph/>, 2024.
- [6] Junkai Li, Yunghwei Lai, Weitao Li, Jingyi Ren, Meng Zhang, Xinhui Kang, Siyu Wang, Peng Li, Ya-Qin Zhang, Weizhi Ma, and Yang Liu. Agent hospital: A simulacrum of hospital with evolvable medical agents. *arXiv preprint arXiv:2405.02957*, 2024.
- [7] Harsha Nori, Yin Tat Lee, Sheng Zhang, Dean Carignan, Richard Edgar, et al. Can generalist foundation models outcompete special-purpose tuning? case study in medicine. *arXiv preprint arXiv:2311.16452*, 2023.
- [8] Ankit Pal, Logesh Kumar Umapathi, and Malaikannan Sankarasubbu. Medmcqa: A large-scale multi-subject multi-choice dataset for medical domain question answering. In *Conference on Health, Inference, and Learning (CHIL)*, 2022.
- [9] Qwen Team. Qwen2.5 technical report. *arXiv preprint arXiv:2412.15115*, 2025.
- [10] Xiangru Tang, Anni Zou, Zhuosheng Zhang, Ziming Li, Yilun Zhao, Xingyao Zhang, Arman Cohan, and Mark Gerstein. Medagents: Large language models as collaborators for zero-shot medical reasoning. In *Findings of the Association for Computational Linguistics (ACL Findings)*, 2024. arXiv:2311.10537.
- [11] Xiangyu Xie, Zhuowen Song, Haozhe Luo, et al. Fine-tuning aligned language models compromises safety, even when users are not malicious. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2025. github.com/ZHIXINXIE/ten_benign.

- [12] Guangzhi Xiong, Qiao Jin, Zhiyong Lu, and Aidong Zhang. Benchmarking retrieval-augmented generation for medicine. *Findings of the Association for Computational Linguistics (ACL)*, 2024.
- [13] Andy Zou, Zifan Wang, Nicholas Carlini, Milad Nasr, J. Zico Kolter, and Matt Fredrikson. Universal and transferable adversarial attacks on aligned language models. 2023.